

UNIVERSIDAD PRIVADA ANTENOR ORREGO

FACULTAD DE INGENIERÍA



PROGRAMA DE ESTUDIO DE INGENIERÍA DE SISTEMAS E INTELIGENCIA ARTIFICIAL

Traducción de Mensajes de Audio con Clonación de Voz mediante Inteligencia Artificial

CURSO:

- Inteligencia artificial, principios y técnicas

DOCENTE:

- Teobaldo Hernan Sagastegui Chigne

AUTORES:

- Portela Pedemonte, Joaquin Antonio
- Villena Gamboa, Arellys Judith
- Araneda Espinola, Sneider
- Valverde Cedron, Sebastian
- Franco Rodriguez, Gustavo
- Mantilla Rodriguez, Sebastian

TRUJILLO - PERÚ
2026

Índice

1. Introducción.....	3
1.1. Título del Proyecto.....	3
1.2. Antecedentes.....	3
1.3. Problema a resolver.....	6
1.4. Objetivos.....	6
1.4.1. Objetivo general.....	6
1.4.2. Objetivos específicos.....	6
2. Requerimientos.....	7
2.1. Definición del Dominio.....	7
2.2. Determinación de Requisitos (Requerimientos).....	7
Referencias.....	10

1. Introducción

1.1. Título del Proyecto

Traducción de Mensajes de Audio con Clonación de Voz mediante Inteligencia Artificial

1.2. Antecedentes

La traducción automática de voz, conocida como Speech-to-Speech Translation (S2ST), busca transformar un mensaje hablado en un idioma de origen en un nuevo mensaje hablado en un idioma de destino. Históricamente, una de las formas más extendidas de resolver este problema ha sido mediante una arquitectura en cascada compuesta por reconocimiento automático del habla (ASR), traducción automática (MT) y síntesis de voz (TTS), donde cada componente se optimiza y evalúa de forma independiente. Inaguma et al. (2023) describen esta organización como el enfoque tradicional de S2ST y la contrastan con arquitecturas directas que intentan aprender la transformación completa entre señales de voz. Esta distinción es relevante para el presente proyecto, ya que permite entender que la traducción de un mensaje de audio puede abordarse como una secuencia modular de problemas de inteligencia artificial y procesamiento del lenguaje hablado, sin que sea obligatorio entrenar un único modelo de extremo a extremo.

Entre los primeros antecedentes modernos de traducción directa de voz se encuentra el trabajo de Jia et al. (2019), quienes propusieron un modelo secuencia a secuencia capaz de traducir directamente espectrogramas de voz de un idioma a otro sin utilizar texto intermedio. Sus experimentos se realizaron precisamente sobre conjuntos de traducción español-inglés y demostraron también la posibilidad de sintetizar la salida con la voz del hablante de origen. Aunque el modelo directo presentó un rendimiento ligeramente inferior frente a una línea base en cascada, el estudio demostró la viabilidad técnica de combinar traducción lingüística y características del hablante dentro de un mismo problema. Para este proyecto, dicho antecedente establece que la traducción de mensajes del español al inglés con conservación de identidad vocal es una línea de investigación previamente documentada, aun cuando la implementación propuesta adopte una arquitectura modular para facilitar el desarrollo, las pruebas y el análisis de cada componente.

Posteriormente, Jia et al. (2022) desarrollaron Translatotron 2, una arquitectura directa de S2ST compuesta por un codificador de voz, un decodificador lingüístico y un sintetizador acústico. El modelo mejoró de forma importante la calidad de traducción y de generación de voz respecto a la primera versión e incorporó un mecanismo específico para preservar la voz de los hablantes en el audio traducido. Este trabajo es uno de los antecedentes más cercanos al objetivo del proyecto porque demuestra que la identidad vocal puede conservarse durante una traducción entre idiomas y no tiene que reemplazarse necesariamente por una voz genérica. Sin embargo, Translatotron 2 requiere entrenamiento conjunto y una arquitectura especializada. El presente proyecto no pretende reproducir ese enfoque de extremo a extremo, sino separar el reconocimiento, la traducción y la síntesis/clonación para poder evaluar cada etapa de manera independiente dentro de un entorno académico reproducible.

La investigación reciente también ha mostrado que estas tareas pueden integrarse a gran escala. Seamless Communication et al. (2023) presentaron SeamlessM4T, un modelo multimodal y multilingüe capaz de realizar reconocimiento automático del habla, traducción de voz a texto, traducción de texto a texto, traducción de texto a voz y traducción de voz a voz para un amplio conjunto de idiomas. El sistema fue construido a partir de grandes cantidades de datos de voz y texto y evidencia el avance hacia modelos unificados de comunicación multilingüe. Asimismo, desarrollos posteriores de la familia Seamless han explorado traducción expresiva y en streaming. Estos trabajos demuestran que características como la traducción, la expresividad y la baja latencia pueden coexistir, pero también evidencian el incremento de complejidad y recursos necesarios cuando se intentan resolver simultáneamente. Por ello, el alcance del presente proyecto se limita deliberadamente a mensajes completos de un solo hablante y no establece el streaming ni la preservación explícita de la emoción como requisitos.

Dentro de una arquitectura modular, la primera tarea es el reconocimiento automático del habla. Radford et al. (2023) desarrollaron Whisper a partir de aproximadamente 680 000 horas de supervisión multilingüe y multitarea. Los autores mostraron que, al escalar los datos de entrenamiento, el modelo obtiene una capacidad de generalización competitiva en diferentes conjuntos de evaluación sin requerir ajuste específico para cada uno. Este resultado es relevante porque permite utilizar un modelo ASR previamente entrenado como componente de inferencia para convertir el audio en español en una transcripción textual, evitando entrenar desde cero un reconocedor de voz. En el proyecto, el ASR será evaluado de manera independiente mediante una transcripción de referencia; de esta forma, un error de reconocimiento podrá distinguirse de un error producido posteriormente por el traductor o por el sistema de síntesis.

La segunda etapa corresponde a la traducción automática neuronal. Junczys-Dowmunt et al. (2018) presentaron Marian como un framework eficiente para modelos neuronales encoder-decoder, mientras que Tiedemann y Thottingal (2020) documentaron OPUS-MT como una iniciativa que pone a disposición una amplia colección de modelos neuronales preentrenados para múltiples pares de idiomas. A mayor escala, el NLLB Team (2024) presentó No Language Left Behind (NLLB-200), un sistema de traducción neuronal que cubre 200 idiomas y que obtuvo mejoras significativas frente a sistemas anteriores en su evaluación multilingüe. Además, el trabajo muestra que un modelo general puede transferirse a dominios específicos mediante fine-tuning con cantidades acotadas de datos paralelos de alta calidad. Esta característica se relaciona directamente con el enfoque académico propuesto: utilizar un modelo de traducción preentrenado como punto de partida y adaptar sus pesos con un corpus paralelo español-inglés, de modo que el proyecto incluya una fase formal de aprendizaje, validación y prueba.

El componente diferenciador del proyecto aparece en la generación del audio final. Arik et al. (2018) definieron la clonación neuronal de voz como la síntesis de nuevos enunciados a partir de una cantidad limitada de muestras de un hablante. Los autores estudiaron dos estrategias: la adaptación del hablante, basada en ajustar un modelo generativo multihablante con muestras de la nueva voz, y la codificación del hablante, que utiliza otro modelo para inferir una representación de la identidad vocal a partir de los audios de referencia. Ambos enfoques mostraron que es posible obtener habla con semejanza respecto al hablante original usando pocas muestras, mientras que el enfoque basado en codificación reduce el costo de memoria y el tiempo de clonación. En el presente proyecto, el término clonación de voz se empleará en este sentido: generar el texto traducido mediante una voz sintética con características reconocibles del emisor, sin afirmar que se obtiene una copia idéntica de su voz.

Jia et al. (2018) profundizaron en la representación del hablante mediante un Speaker Encoder entrenado para verificación de voz. Este componente transforma pocos segundos de audio de referencia en un vector de dimensión fija denominado speaker embedding. El embedding condiciona posteriormente un sistema de síntesis para generar nuevas frases con características del hablante, incluso cuando esa persona no estuvo presente en el entrenamiento del sintetizador. Este antecedente es importante por dos motivos. Primero, explica técnicamente cómo puede representarse la identidad vocal a partir de la misma señal de entrada que se desea traducir. Segundo, proporciona una base para evaluar la salida: un codificador de hablante preentrenado puede extraer embeddings tanto del audio original como del audio generado y comparar su similitud, sin necesidad de reentrenar dicho codificador dentro del proyecto.

Los sistemas Zero-Shot extienden este principio al permitir generar la voz de hablantes no observados durante el entrenamiento. Casanova et al. (2022) presentaron YourTTS, un modelo multihablante y multilingüe orientado a síntesis y conversión de voz Zero-Shot, mostrando que una referencia breve puede emplearse para producir habla de un nuevo hablante sin entrenar un modelo independiente para cada usuario. Más recientemente, Casanova et al. (2024) presentaron XTTS, un modelo multilingüe de Zero-Shot TTS entrenado en 16 idiomas y diseñado para mejorar la clonación de voz y acelerar entrenamiento e inferencia. De manera complementaria, Qin et al. (2023) propusieron OpenVoice, que aborda clonación instantánea y Zero-Shot cross-lingual separando el color vocal del hablante de otros atributos de estilo. Estos antecedentes respaldan la viabilidad de utilizar la misma entrada de audio como referencia vocal y sintetizar la traducción en otro idioma sin realizar entrenamiento específico para cada persona.

En conjunto, la literatura revisada muestra que cada parte del título del proyecto tiene sustento en soluciones documentadas: la traducción de mensajes de audio se relaciona con los sistemas S2ST; el contenido lingüístico puede recuperarse mediante ASR y transformarse mediante traducción neuronal; y la clonación de voz puede realizarse mediante representaciones de hablante y síntesis Zero-Shot. A partir de estos antecedentes, el proyecto adopta una arquitectura modular compuesta por un ASR preentrenado, un modelo de traducción neuronal preentrenado que será adaptado mediante fine-tuning y un modelo preentrenado de clonación de voz Zero-Shot. El mismo audio de entrada será utilizado como referencia de identidad vocal. El alcance se limita inicialmente a español como idioma origen, inglés como idioma destino, un solo hablante por mensaje y procesamiento no streaming, dejando fuera la preservación explícita de emoción, la transferencia exacta de prosodia y el entrenamiento desde cero de modelos de voz.

1.3. Problema a resolver

Los sistemas de traducción de voz permiten trasladar el contenido lingüístico de un idioma a otro; sin embargo, en una arquitectura convencional basada en ASR, traducción y TTS, la etapa final puede sintetizar el mensaje con una voz genérica o distinta de la del emisor. Como consecuencia, aunque el contenido traducido sea comprensible, se pierde una característica relevante de la comunicación hablada: la continuidad de identidad entre la voz del mensaje original y la voz del mensaje traducido. Los trabajos sobre clonación neuronal, speaker embeddings y traducción Speech-to-Speech con preservación del hablante muestran que esta limitación puede abordarse mediante una referencia vocal que condicione el proceso de síntesis (Arik et al., 2018; Jia et al., 2018; Jia et al., 2022).

El planteamiento inicial del proyecto buscaba resolver simultáneamente traducción, clonación de voz, preservación emocional y funcionamiento en tiempo real con una latencia reducida. Esa combinación introduce exigencias adicionales de streaming, segmentación incremental, sincronización y optimización de inferencia que dificultan aislar el aprendizaje de cada componente y aumentan considerablemente la demanda computacional. Debido a que la ejecución académica se realizará principalmente en Google Colab con recursos de GPU variables, mantener una restricción rígida de tiempo real no resulta consistente con un prototipo cuyo objetivo principal es estudiar y evaluar el procesamiento del lenguaje hablado y la preservación de identidad vocal.

Por ello, el problema se reformula hacia la traducción de mensajes completos de audio. El sistema deberá recibir una entrada de un único hablante, obtener su transcripción en español, traducir el contenido al inglés y generar un nuevo audio utilizando como referencia vocal el mismo mensaje de entrada. La clonación se realizará mediante un modelo Zero-Shot previamente entrenado, de modo que no sea necesario entrenar una voz individual para cada usuario. La salida se entenderá como una aproximación sintética de la identidad del hablante y no como una réplica exacta ni como una conservación garantizada de emoción, ritmo o prosodia.

A nivel académico, el proyecto también debe permitir distinguir entre integración e aprendizaje. Por esa razón, el ASR y el modelo de clonación de voz se utilizarán principalmente en inferencia con pesos preentrenados, mientras que el módulo de traducción será adaptado mediante fine-tuning sobre un corpus paralelo español-inglés. De esta manera, el sistema conservará una etapa formal de entrenamiento, validación y prueba, y al mismo tiempo podrá evaluarse modularmente para identificar si los errores provienen del reconocimiento, de la traducción o de la síntesis final.

1.4. Objetivos

1.4.1. Objetivo general

Desarrollar un sistema basado en inteligencia artificial capaz de traducir mensajes de audio del español al inglés y generar el contenido traducido mediante clonación de voz Zero-Shot, utilizando el mismo audio de entrada como referencia de las características vocales del hablante.

1.4.2. Objetivos específicos

- Implementar un módulo de reconocimiento automático del habla (ASR/STT) basado en un modelo preentrenado para obtener la transcripción del mensaje de audio en español.

- Adaptar mediante fine-tuning un modelo preentrenado de traducción automática neuronal (NMT) utilizando un corpus paralelo español-inglés y evaluar su desempeño frente al modelo base.
- Preparar la señal de entrada para que el mismo mensaje de audio pueda utilizarse tanto en la rama de reconocimiento del habla como en la obtención de la referencia de identidad vocal.
- Integrar un modelo preentrenado de síntesis y clonación de voz Zero-Shot capaz de generar en inglés el contenido traducido utilizando como referencia la voz del hablante original.
- Integrar los módulos de reconocimiento, traducción y clonación de voz en un flujo funcional de procesamiento de mensajes completos de audio.
- Evaluar de forma modular y de extremo a extremo la calidad de la transcripción, la traducción, la similitud vocal, la calidad del audio generado y el tiempo de procesamiento.

2. Requerimientos

2.1. Definición del Dominio

El dominio de aplicación corresponde al procesamiento del lenguaje hablado mediante inteligencia artificial, específicamente a la traducción automática Speech-to-Speech de mensajes de voz con preservación aproximada de la identidad vocal del hablante. El sistema integra técnicas de reconocimiento automático del habla, procesamiento del lenguaje natural, traducción automática neuronal y síntesis de voz condicionada por una referencia de hablante.

El escenario inicial se delimita a mensajes completos emitidos por un solo hablante, con español como idioma de origen e inglés como idioma de destino. La entrada principal será un archivo de audio; si se admite un archivo de video como contenedor, el sistema procesará únicamente su pista de audio, sin incorporar análisis de imagen ni visión por computadora. El mismo audio de entrada servirá como fuente para la transcripción y como referencia vocal para la etapa de clonación.

El sistema está planteado como un prototipo académico reproducible en Google Colab y no como un servicio de conversación simultánea. Por ello, el procesamiento se realizará después de recibir el mensaje completo y no se establecerá una latencia máxima de tiempo real. El propósito es comprobar que un pipeline modular de IA puede mantener el contenido lingüístico durante la traducción y generar una salida en otro idioma con una identidad vocal semejante a la del emisor, permitiendo además evaluar cada componente de forma independiente.

2.2. Determinación de Requisitos (Requerimientos)

Requerimientos Técnicos

- Entorno principal de ejecución en Google Colab con acceso a una GPU compatible con CUDA. No se fijará un modelo específico de GPU debido a la asignación variable de recursos de la plataforma.
- Python como lenguaje de desarrollo y un framework de Deep Learning compatible con los modelos seleccionados, principalmente PyTorch y librerías del ecosistema de procesamiento de lenguaje y audio.

- Herramientas para decodificación, extracción de pista, conversión de formato y remuestreo de audio, como FFmpeg y librerías de procesamiento de señal compatibles con Python.
- Modelo ASR preentrenado con soporte para español. Este componente se utilizará en inferencia y no requerirá entrenamiento propio dentro del alcance inicial.
- Modelo preentrenado de traducción automática neuronal compatible con español-inglés y susceptible de fine-tuning. Este será el componente sometido a adaptación de pesos durante el proyecto.
- Corpus paralelo español-inglés con particiones de entrenamiento, validación y prueba para realizar el fine-tuning y evaluar el modelo de traducción.
- Modelo preentrenado de clonación de voz o TTS Zero-Shot con capacidad cross-lingual, capaz de utilizar una referencia breve del mismo hablante y sintetizar el texto traducido en inglés sin entrenamiento específico por usuario.
- Modelo o codificador de hablante preentrenado para la evaluación objetiva de similitud vocal mediante embeddings, sin reentrenamiento dentro del proyecto.
- Conjunto de audios de evaluación con transcripción y traducción de referencia, utilizando voces cuya participación y uso hayan sido autorizados, para realizar pruebas modulares y de extremo a extremo.
- Repositorio GitHub para control de versiones y almacenamiento de código, notebooks y documentación, además de una interfaz de demostración compatible con Google Colab para ejecutar el pipeline completo.

Requerimientos Funcionales

- El sistema debe permitir cargar un mensaje de audio en un formato soportado y verificar que pueda ser procesado correctamente.
- El sistema debe procesar entradas correspondientes a un solo hablante y utilizar el mensaje completo antes de iniciar la traducción; no se considera streaming dentro del alcance.
- El sistema debe generar y mostrar la transcripción del audio de entrada en español.
- El sistema debe traducir la transcripción obtenida del español al inglés utilizando el modelo de traducción seleccionado y posteriormente ajustado.
- El sistema debe utilizar el mismo audio de entrada como referencia para obtener las características de identidad vocal necesarias para la síntesis.
- El sistema debe generar un audio en inglés mediante clonación de voz Zero-Shot, buscando conservar características reconocibles del hablante original.
- El sistema debe permitir reproducir y conservar el audio generado, además de mostrar los resultados intermedios necesarios para verificar transcripción y traducción.
- El sistema debe registrar los resultados de cada módulo para facilitar el testing independiente de ASR, traducción y clonación de voz.
- El sistema debe informar cuando un archivo no pueda procesarse por formato, ausencia de pista de audio u otra condición técnica incompatible.
- Si se habilita compatibilidad con archivos de video, el sistema debe extraer únicamente la pista de audio y continuar con el mismo pipeline, sin analizar el contenido visual.

Condiciones y restricciones del alcance

- La primera versión se limitará a español como idioma origen e inglés como idioma destino.

- No se implementará diarización ni traducción de múltiples hablantes dentro de un mismo mensaje.
- No se exigirá traducción en tiempo real, streaming ni una latencia máxima fija.
- No se considerará como requisito la preservación explícita de emociones, ritmo, pausas o prosodia completa.
- El proyecto no entrenará desde cero los modelos de ASR ni de clonación de voz; ambos se utilizarán con pesos preentrenados. El aprendizaje propio se concentrará en el fine-tuning del módulo de traducción.
- La voz generada será evaluada como una aproximación de identidad vocal y no como una copia exacta del hablante.
- Los modelos seleccionados deberán permitir uso académico conforme a sus licencias y los audios empleados para evaluación deberán contar con autorización de sus participantes.

Referencias

- Arik, S. O., Chen, J., Peng, K., Ping, W., & Zhou, Y. (2018). Neural Voice Cloning with a Few Samples. *Advances in Neural Information Processing Systems*, 31. <https://proceedings.neurips.cc/paper/2018/hash/4559912e7a94a9c32b09d894f2bc3c82-Abstract.html>
- Casanova, E., Weber, J., Shulby, C. D., Candido Junior, A., Gölge, E., & Ponti, M. A. (2022). YourTTS: Towards Zero-Shot Multi-Speaker TTS and Zero-Shot Voice Conversion for Everyone. *Proceedings of the 39th International Conference on Machine Learning*, 162, 2709-2720. <https://proceedings.mlr.press/v162/casanova22a.html>
- Casanova, E., Davis, K., Gölge, E., Gökner, G., Gulea, I., Hart, L., Aljafari, A., Meyer, J., Morais, R., Olayemi, S., & Weber, J. (2024). XTTS: a Massively Multilingual Zero-Shot Text-to-Speech Model. *Interspeech 2024*, 4978-4982. <https://doi.org/10.21437/Interspeech.2024-2016>
- Inaguma, H., Popuri, S., Kulikov, I., Chen, P.-J., Wang, C., Chung, Y.-A., Tang, Y., Lee, A., Watanabe, S., & Pino, J. (2023). UnitY: Two-pass Direct Speech-to-speech Translation with Discrete Units. *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics*, 15655-15680. <https://doi.org/10.18653/v1/2023.acl-long.872>
- Jia, Y., Ramanovich, M. T., Remez, T., & Pomerantz, R. (2022). Translatotron 2: High-quality direct speech-to-speech translation with voice preservation. *Proceedings of the 39th International Conference on Machine Learning*, 162, 10120-10134. <https://proceedings.mlr.press/v162/jia22b.html>
- Jia, Y., Weiss, R. J., Biadys, F., Macherey, W., Johnson, M., Chen, Z., & Wu, Y. (2019). Direct Speech-to-Speech Translation with a Sequence-to-Sequence Model. *Interspeech 2019*, 1123-1127. <https://doi.org/10.21437/Interspeech.2019-1951>
- Jia, Y., Zhang, Y., Weiss, R. J., Wang, Q., Shen, J., Ren, F., Chen, Z., Nguyen, P., Pang, R., Lopez Moreno, I., & Wu, Y. (2018). Transfer Learning from Speaker Verification to Multispeaker Text-To-Speech Synthesis. *Advances in Neural Information Processing Systems*, 31. <https://proceedings.neurips.cc/paper/2018/hash/6832a7b24bc06775d02b7406880b93fc-Abstract.html>
- Junczys-Dowmunt, M., Grundkiewicz, R., Dwojak, T., Hoang, H., Heafield, K., Neckermann, T., Seide, F., Hermann, U., Aji, A. F., Bogoychev, N., Martins, A. F. T., & Birch, A. (2018). Marian: Fast Neural Machine Translation in C++. *Proceedings of ACL 2018, System Demonstrations*, 116-121. <https://doi.org/10.18653/v1/P18-4020>
- NLLB Team. (2024). Scaling neural machine translation to 200 languages. *Nature*, 630, 841-846. <https://doi.org/10.1038/s41586-024-07335-x>
- Qin, Z., Zhao, W., Yu, X., & Sun, X. (2023). OpenVoice: Versatile Instant Voice Cloning. *arXiv preprint arXiv:2312.01479*. <https://arxiv.org/abs/2312.01479>
- Radford, A., Kim, J. W., Xu, T., Brockman, G., Mcleavy, C., & Sutskever, I. (2023). Robust Speech Recognition via Large-Scale Weak Supervision. *Proceedings of the 40th International Conference on Machine Learning*, 202, 28492-28518. <https://proceedings.mlr.press/v202/radford23a.html>
- Seamless Communication, Barrault, L., Chung, Y.-A., Cora Meglioli, M., Dale, D., Dong, N., Duquenne, P.-A., Elshahar, H., Gong, H., Heffernan, K., et al. (2023). SeamlessM4T: Massively Multilingual & Multimodal Machine Translation. *arXiv preprint arXiv:2308.11596*. <https://arxiv.org/abs/2308.11596>
- Tiedemann, J., & Thottingal, S. (2020). OPUS-MT - Building open translation services for the World. *Proceedings of the 22nd Annual Conference of the European Association for Machine Translation*, 479-480. <https://aclanthology.org/2020.eamt-1.61/>